


차원축소: PCA & MDS



1. PCA (주성분분석) 소개
2. PCA 실습
3. MDS (다차원척도) 소개
4. MDS 실습

1. Principal Component Analysis (주성분분석)

1. 소개



- 더 적은 수의 변수/차원(Principal Component)으로 원 데이터의 변동(variation)을 표현하기 위한 방법
 - ✓ 사용되는 데이터는 연속형 변수 (독립/종속 개념 없음)
 - ✓ 원 데이터의 **변수들이 많고**, 그들 간에 **상관관계가 높을 때** 유용
 - ✓ 주성분은 원 데이터의 **선형 결합**으로 표현
 - ✓ 주성분 간에는 **상관관계가 없도록** 추출(orthogonal)
- 예제
 - ✓ 독립변수 간에 **상관관계가 높을 때**
 - ✓ 데이터를 **압축해서** 저장
 - ✓ 고차원 데이터를 **2/3 차원으로** 시각화해서 표현
 - ✓ 수학능력을 평가하는 **종합 지표**를 개발

1. Principal Component Analysis (주성분분석)

Principal Component Analysis (PCA) problem formulation

$$3D \rightarrow 2D$$

$$K = 2$$




Reduce from 2-dimension to 1-dimension: Find a direction (a vector $u^{(1)} \in \mathbb{R}^n$) onto which to project the data so as to minimize the projection error.

Reduce from n-dimension to k-dimension Find k vectors $u^{(1)}, u^{(2)}, \dots, u^{(k)}$ onto which to project the data, so as to minimize the projection error.



1. Principal Component Analysis (주성분분석)

PCA is not linear regression



Source: Machine Learning by Andrew Ng at Coursera.org


Andrew Ng

차원축소: PCA & MDS

*PCA vs. LDA


PCA:

component axes that maximize the variance



LDA:

maximizing the component axes for class-separation




https://sebastianraschka.com/Articles/2014_python_lda.html

*공분산행렬, 고유벡터, 주성분 분석

1. (정의) A 를 $n \times n$ 행렬이라고 할 때, $A\mathbf{x} = \lambda\mathbf{x}$ 를 만족하는 영벡터가 아닌 벡터 \mathbf{x} 가 존재할 때, 스칼라 λ 를 A 의 **고유값(eigen value)**이라 하고 벡터 \mathbf{x} 는 λ 에 관련된 **고유벡터(eigen vector)**라 한다.
2. (의미) \mathbf{x} 가 A 의 고유벡터이면 $A\mathbf{x}$ 는 \mathbf{x} 의 스칼라배
이므로 고유값 λ 의 값에 따라 $A\mathbf{x}$ 는 \mathbf{x} 를 확장, 축소,
반대방향 등으로 만든다.
3. (예제) 벡터 $\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 는 고유값 $\lambda = 3$ 에 대응하는 행렬
 $A = \begin{bmatrix} 3 & 0 \\ 8 & -1 \end{bmatrix}$ 의 고유벡터이다. 왜냐하면 $A\mathbf{x} =$
 $\begin{bmatrix} 3 & 0 \\ 8 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \end{bmatrix} = 3\mathbf{x}$ 이기 때문.

*공분산행렬, 고유벡터, 주성분 분석

1. 고유벡터는 그 행렬이 벡터에 작용하는 힘의 방향을 나타내므로 $n \times n$ 공분산 행렬의 **고유 벡터는 데이터가 어떤 방향으로 분산되어 있는지(주성분의 방향)를 표현.**
 - n = 기존 차원의 수
2. 고유값은 고유벡터에 대한 계수에 해당하므로, **고유값이 큰 순서대로** 고유 벡터를 정렬하면 결과적으로 중요한 순서대로 주성분을 구한 셈 (**고유값은 주성분으로 projected된 분산값을 표현**).





2. PCA 방법

1. 미국 주 별 범죄율 (USArrests)

- A data frame with 50 observations on 4 variables.
 - ✓ Murder numeric Murder arrests (per 100,000) in 1973
 - ✓ Assault numeric Assault arrests (per 100,000) in 1973
 - ✓ UrbanPop numeric Percent urban population in 1973
 - ✓ Rape numeric Rape arrests (per 100,000) in 1973

```
# ① 자료 확인(R 내장 데이터)  
USArrests  
str(USArrests)  
# ② 분산 확인  
var(USArrests)  
diag(var(USArrests))  
sum(diag(var(USArrests)))  
# ③ PCA 수행  
pca.out <- prcomp(USArrests)  
pca.out  
summary(pca.out)
```



2. PCA 방법

- ✓ USArrests 데이터를 확인
 - var 함수를 통해 변수의 분산(and 공분산)을 확인
 - sum 함수를 통해 총 분산을 확인
- ✓ 주성분분석을 시행하기 위해 prcomp 함수를 이용
 - prcomp 함수에는 변수들의 관측치가 저장된 data frame을 입력
 - 종속변수, 독립변수 개념이 없음
 - summary 함수에 이 객체를 지정하면 분석 결과를 확인

2. PCA 방법

```
> var(USArrests)
      Murder      Assault      UrbanPop      Rape
Murder    18.970465    291.0624    4.386204    22.99141
Assault   291.062367   6945.1657   312.275102   519.26906
UrbanPop    4.386204    312.2751   209.518776    55.76808
Rape       22.991412    519.2691    55.768082    87.72916
> diag(var(USArrests))
      Murder      Assault      UrbanPop      Rape
      18.97047  6945.16571   209.51878    87.72916
> sum(diag(var(USArrests)))
[1] 7261.384
> pca.out <- prcomp(USArrests)
> pca.out
Standard deviations (1, ..., p=4):
[1] 83.732400 14.212402  6.489426  2.482790

Rotation (n x k) = (4 x 4):
      PC1      PC2      PC3      PC4
Murder  0.04170432 -0.04482166  0.07989066 -0.99492173
Assault  0.99522128 -0.05876003 -0.06756974  0.03893830
UrbanPop 0.04633575  0.97685748 -0.20054629 -0.05816914
Rape     0.07515550  0.20071807  0.97408059  0.07232502>
> summary(pca.out)
Importance of components:
      PC1      PC2      PC3      PC4
Standard deviation  83.7324 14.21240 6.4894 2.48279
Proportion of Variance 0.9655 0.02782 0.0058 0.00085
Cumulative Proportion 0.9655 0.99335 0.9991 1.00000
```



2. PCA 방법

- 분석결과
 - ✓ prcomp 함수를 통해 주성분 4개(PC1, 2, 3, 4)를 도출
 - 첫 줄에 각 PC의 표준편차를 표시
 - PC를 구성하기 위한 각 변수의 weight/loading value)를 표시
 - » $PC1 = 0.04170432 * Murder(centered) + 0.99522128 * Assault(centered) + 0.04633575 * UrbanPop(centered) + 0.07515550 * Rape(centered)$

```
#manually calculate score for PC1 (in case of Alabama)
USArrests.centered = scale(USArrests, center = T, scale = F)
head(USArrests.centered)
USArrests.centered[1,]
USArrests[1,]
pca.out$center      #difference between original and centered values
pca.out$rotation[,1] #weight for each dimension
sum(USArrests.centered[1,]*pca.out$rotation[,1])
head(pca.out$x)     #score of Principal Components
```

- ✓ summary 함수를 통해 총 분산 중 각 PC가 설명하는 부분을 계산
 - PC1이 전체 분산 중 96.6%를 설명
 - PC2까지 포함하면 2개의 성분으로 전체 분산의 99.3%를 설명 가능

* PCA결과와 고유벡터/고유값의 관계

```
> #eigen vector = PC, eigen value = PC's variance
> pca.eigen <- eigen(var(USArrests))
> pca.eigen$vectors
```

	[,1]	[,2]	[,3]	[,4]
[1,]	-0.04170432	0.04482166	0.07989066	0.99492173
[2,]	-0.99522128	0.05876003	-0.06756974	-0.03893830
[3,]	-0.04633575	-0.97685748	-0.20054629	0.05816914
[4,]	-0.07515550	-0.20071807	0.97408059	-0.07232502

```
> pca.out
Standard deviations (1, ..., p=4):
[1] 83.732400 14.212402 6.489426 2.482790

Rotation (n x k) = (4 x 4):
```

	PC1	PC2	PC3	PC4
Murder	0.04170432	-0.04482166	0.07989066	-0.99492173
Assault	0.99522128	-0.05876003	-0.06756974	0.03893830
UrbanPop	0.04633575	0.97685748	-0.20054629	-0.05816914
Rape	0.07515550	0.20071807	0.97408059	0.07232502

```
> pca.eigen$values
[1] 7011.114851 201.992366 42.112651 6.164246
> pca.out$sdev^2
[1] 7011.114851 201.992366 42.112651 6.164246
> pca.eigen$values/sum(pca.eigen$values)
[1] 0.9655342206 0.0278173366 0.0057995349 0.0008489079
> summary(pca.out)
Importance of components:
```

	PC1	PC2	PC3	PC4
Standard deviation	83.7324	14.21240	6.4894	2.48279
Proportion of Variance	0.9655	0.02782	0.0058	0.00085
Cumulative Proportion	0.9655	0.99335	0.9991	1.00000




2. PCA 방법

```
> pca.out$x
```

	PC1	PC2	PC3	PC4
Alabama	64.802164	-11.4480074	-2.49493284	-2.4079009
Alaska	92.827450	-17.9829427	20.12657487	4.0940470

```
...  
> biplot(pca.out)
```



& MDS



2. PCA 방법

```
> biplot(pca.out, scale = F)
> #left & bottom axes: scores of PC1 and PC2 (data points)
> #right & top axes: loading values of PC1 and PC2 (arrows)
> apply(pca.out$x, 2, range) #print out min/max values of PCs
```

	PC1	PC2	PC3	PC4
[1,]	-127.4956	-31.09662	-17.47002	-7.343673
[2,]	165.2444	24.29121	20.12657	4.353685

```
> pca.out
Standard deviations (1, .., p=4):
[1] 83.732400 14.212402 6.489426 2.482790
```

Rotation (n x k) = (4 x 4):

	PC1	PC2	PC3	PC4
Murder	0.04170432	-0.04482166	0.07989066	-0.99492173
Assault	0.99522128	-0.05876003	-0.06756974	0.03893830
UrbanPop	0.04633575	0.97685748	-0.20054629	-0.05816914
Rape	0.07515550	0.20071807	0.97408059	0.07232502



2. PCA 방법

- 분산 값이 큰 Assault가 PCA 결과를 좌우하는 상황을 개선하기 위해 표준화 처리된 데이터를 사용하는 것이 바람직
 ✓ scale 함수를 사용하거나, prcomp의 scale. 옵션을 사용

```
# ① 자료 표준화 후 PCA
> USArrests.scaled <- scale(USArrests) #scale 함수로 표준화
> var(USArrests.scaled)
> cor(USArrests) #표준화 한 뒤의 공분산행렬은 상관행렬과 동일
> pca.out <- prcomp(USArrests, scale. = T) #scale. 옵션으로 표준화
> pca.out
# ② 결과 확인
> summary(pca.out)
> biplot(pca.out)
```

2. PCA 방법

```
> scale(USArrests)
```

	Murder	Assault	UrbanPop	Rape
Alabama	1.24256408	0.78283935	-0.52090661	-0.003416473
Alaska	0.50786248	1.10682252	-1.21176419	2.484202941
...				

```
> pca.out <- prcomp(USArrests, scale. = T)
> pca.out
Standard deviations (1, ..., p=4):
[1] 1.5748783 0.9948694 0.5971291 0.4164494

Rotation (n x k) = (4 x 4):
```

	PC1	PC2	PC3	PC4
Murder	-0.5358995	0.4181809	-0.3412327	0.64922780
Assault	-0.5831836	0.1879856	-0.2681484	-0.74340748
UrbanPop	-0.2781909	-0.8728062	-0.3780158	0.13387773
Rape	-0.5434321	-0.1673186	0.8177779	0.08902432


```
> summary(pca.out)
Importance of components:
```

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.59713	0.41645
Proportion of Variance	0.6201	0.2474	0.08914	0.04336
Cumulative Proportion	0.6201	0.8675	0.95664	1.00000

```
> biplot(pca.out)
```



2. PCA 방법





* PCA결과와 고유벡터/고유값의 관계

```
> #eigen vector = PC, eigen value = PC's variance
> pca.eigen <- eigen(cor(USArrests)) #correlation matrix
> pca.eigen$vectors
```

```
      [,1]      [,2]      [,3]      [,4]
[1,] -0.5358995  0.4181809 -0.3412327  0.64922780
[2,] -0.5831836  0.1879856 -0.2681484 -0.74340748
[3,] -0.2781909 -0.8728062 -0.3780158  0.13387773
[4,] -0.5434321 -0.1673186  0.8177779  0.08902432
```

```
> pca.out
```

Standard deviations (1, ..., p=4):

```
[1] 1.5748783 0.9948694 0.5971291 0.4164494
```

Rotation (n x k) = (4 x 4):

	PC1	PC2	PC3	PC4
Murder	-0.5358995	0.4181809	-0.3412327	0.64922780
Assault	-0.5831836	0.1879856	-0.2681484	-0.74340748
UrbanPop	-0.2781909	-0.8728062	-0.3780158	0.13387773
Rape	-0.5434321	-0.1673186	0.8177779	0.08902432

```
> pca.eigen$values
```

```
[1] 2.4802416 0.9897652 0.3565632 0.1734301
```

```
> pca.out$sdev^2
```

```
[1] 2.4802416 0.9897652 0.3565632 0.1734301
```

```
> pca.eigen$values/sum(pca.eigen$values)
```

```
[1] 0.62006039 0.24744129 0.08914080 0.04335752
```

```
> summary(pca.out)
```

Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.59713	0.41645
Proportion of Variance	0.6201	0.2474	0.08914	0.04336
Cumulative Proportion	0.6201	0.8675	0.95664	1.00000



2. PCA 방법

```
> biplot(pca.out, scale = F)
> #left & bottom axes: scores of PC1 and PC2 (data points)
> #right & top axes: loading values of PC1 and PC2 (arrows)
> apply(pca.out$x, 2, range) #print out min/max values of PCs
```

	PC1	PC2	PC3	PC4
[1,]	-2.982760	-1.554676	-1.356177	-0.9447896
[2,]	2.962152	2.369737	2.019500	1.0659745

```
> pca.out
Standard deviations (1, ..., p=4):
[1] 1.5748783 0.9948694 0.5971291 0.4164494
```

Rotation (n x k) = (4 x 4):

	PC1	PC2	PC3	PC4
Murder	-0.5358995	0.4181809	-0.3412327	0.64922780
Assault	-0.5831836	0.1879856	-0.2681484	-0.74340748
UrbanPop	-0.2781909	-0.8728062	-0.3780158	0.13387773
Rape	-0.5434321	-0.1673186	0.8177779	0.08902432





2. PCA 방법(성분 개수 선택)

```
> summary(pca.out)
```


Importance of components:

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.59713	0.41645
Proportion of Variance	0.6201	0.2474	0.08914	0.04336
Cumulative Proportion	0.6201	0.8675	0.95664	1.00000

얼마나 많은 정보를
keep 할 것인가?

```
> screeplot(pca.out, type = "l")
```

설명력이 급격히 떨어지는 구간은 어디인가?





2. PCA 방법(수치 계산 확인)

```
#manually calculate score for each record
head(pca.out$x) #score
pca.out$rotation #loading
pca.out$rotation[,1] #loading values of original vars. on PC1
head(USArrests.scaled)
USArrests.scaled[1, ] #standardized values of Alabama
USArrests.scaled[1, ] * pca.out$rotation[,1]
sum(USArrests.scaled[1, ] * pca.out$rotation[,1]) #PC1 score for
Alabama

#manually calculate variances explained by each PC
pca.out
pca.out$sdev #sdev of each PC
pca.out$sdev^2 # var of each PC
pca.out$sdev^2/sum(pca.out$sdev^2) #explained portion by each PC
summary(pca.out) #compare with prcomp output
```




2. Multi-Dimensional Scaling (다차원척도법)

1. 소개


- 유사한 것들끼리 가깝게, 이질적인 것들끼리 멀게 배치하는 방법
 - ✓ 데이터들 간의 거리(or 유사도)를 계산하여 그 거리(or 유사도)가 유지되도록 2/3 차원 공간 상에 배치
- 분석 알고리즘
 - ✓ 다차원 공간에 원 데이터포인트를 정의하고 데이터포인트 간 거리를 계산
 - ✓ 만들어질 축소된 차원의 개수를 정의(일반적으로 2)
 - ✓ 축소된 차원에 데이터포인트들을 초기 배치
 - ✓ 축소된 차원에서 데이터포인트 간 거리를 원래 차원에서 거리와 비교(stress 계산)
 - ✓ 모든 데이터포인트에서 stress를 최소화하는 쪽으로 위치를 보정
- 예제
 - ✓ 고차원 데이터를 2/3 차원으로 시각화해서 표현
 - ✓ 기존 제품들에 대한 고객 인식을 조사하여 신제품 개발 컨셉을 발굴
- 유형
 - ✓ Metric (객관적 거리: ex. 도시 간 거리)
 - ✓ Non-metric (주관적/추상적 거리: ex. 갤럭시폰과 아이폰 차이)

2. Multi-Dimensional Scaling (다차원척도법)



Dataset of n objects and m attributes

e.g. Euclidean distance



n -by- n Proximity matrix (symmetric)

MDS



Spatial configuration of n objects where the between-object distances are representations of corresponding proximities

Source: https://rpubs.com/Shahin/MDS_1

*Stress 공식

1. General stress =
$$\sqrt{\frac{\sum \sum (f(x_{ij}) - d_{ij})^2}{scale}}$$

- d_{ij} : original distance between points i and j
- $f(x_{ij})$: Some function of the input data
- Scale: A constant scaling factor

2. Kruskal's stress =
$$\sqrt{\frac{\sum \sum (f(x_{ij}) - d_{ij})^2}{\sum \sum d_{ij}^2}}$$

- In metric MDS, $f(x_{ij}) = x_{ij}$; distance in new coordinates
- In non-metric MDS, $f(x_{ij})$ is a monotonic transformation of the input data



2. MDS 방법

1. Metric MDS (Classical MDS or Principal Coordinate Analysis)

- 10개 미국 도시 간 직선거리(km) 행렬(UScitiesD)을 활용하여 MDS 수행
 - ✓ (참고)유럽 도시 간 도로상 거리(km)는 eurodist
- 거리행렬을 만들기 위해서는 dist() 함수를 사용
 - ✓ Ex. USArrestsDist <- dist(USArrests.scaled)

```
# ① 자료 확인(거리 행렬)
UScitiesD
# ② metric 다차원척도 분석
mmds.out <- cmdscale(UScitiesD)
mmds.out
# ③ 그림으로 확인
plot(mmds.out)
plot(mmds.out, type = "n")
text(mmds.out, rownames(mmds.out))
```

2. MDS 방법

```
> UScitiesD
```

	Atlanta	Chicago	Denver	Houston	LosAngeles	Miami	NewYork
Chicago	587						
Denver	1212	920					
Houston	701	940	879				
LosAngeles	1936	1745	831	1374			
Miami	604	1188	1726	968	2339		
NewYork	748	713	1631	1420	2451	1092	
SanFrancisco	2139	1858	949	1645	347	2594	2571

```
...
```

```
> mmds.out <- cmdscale(UScitiesD)
```

```
> mmds.out
```

	[,1]	[,2]
Atlanta	-718.7594	142.99427
Chicago	-382.0558	-340.83962
Denver	481.6023	-25.28504
Houston	-161.4663	572.76991
LosAngeles	1203.7380	390.10029
Miami	-1133.5271	581.90731
NewYork	-1072.2357	-519.02423
SanFrancisco	1420.6033	112.58920
Seattle	1341.7225	-579.73928
Washington.DC	-979.6220	-335.47281

```
> plot(mmds.out)
```


```
> plot(mmds.out, type = "n")
```

```
> text(mmds.out, rownames(mmds.out))
```



2. MDS 방법

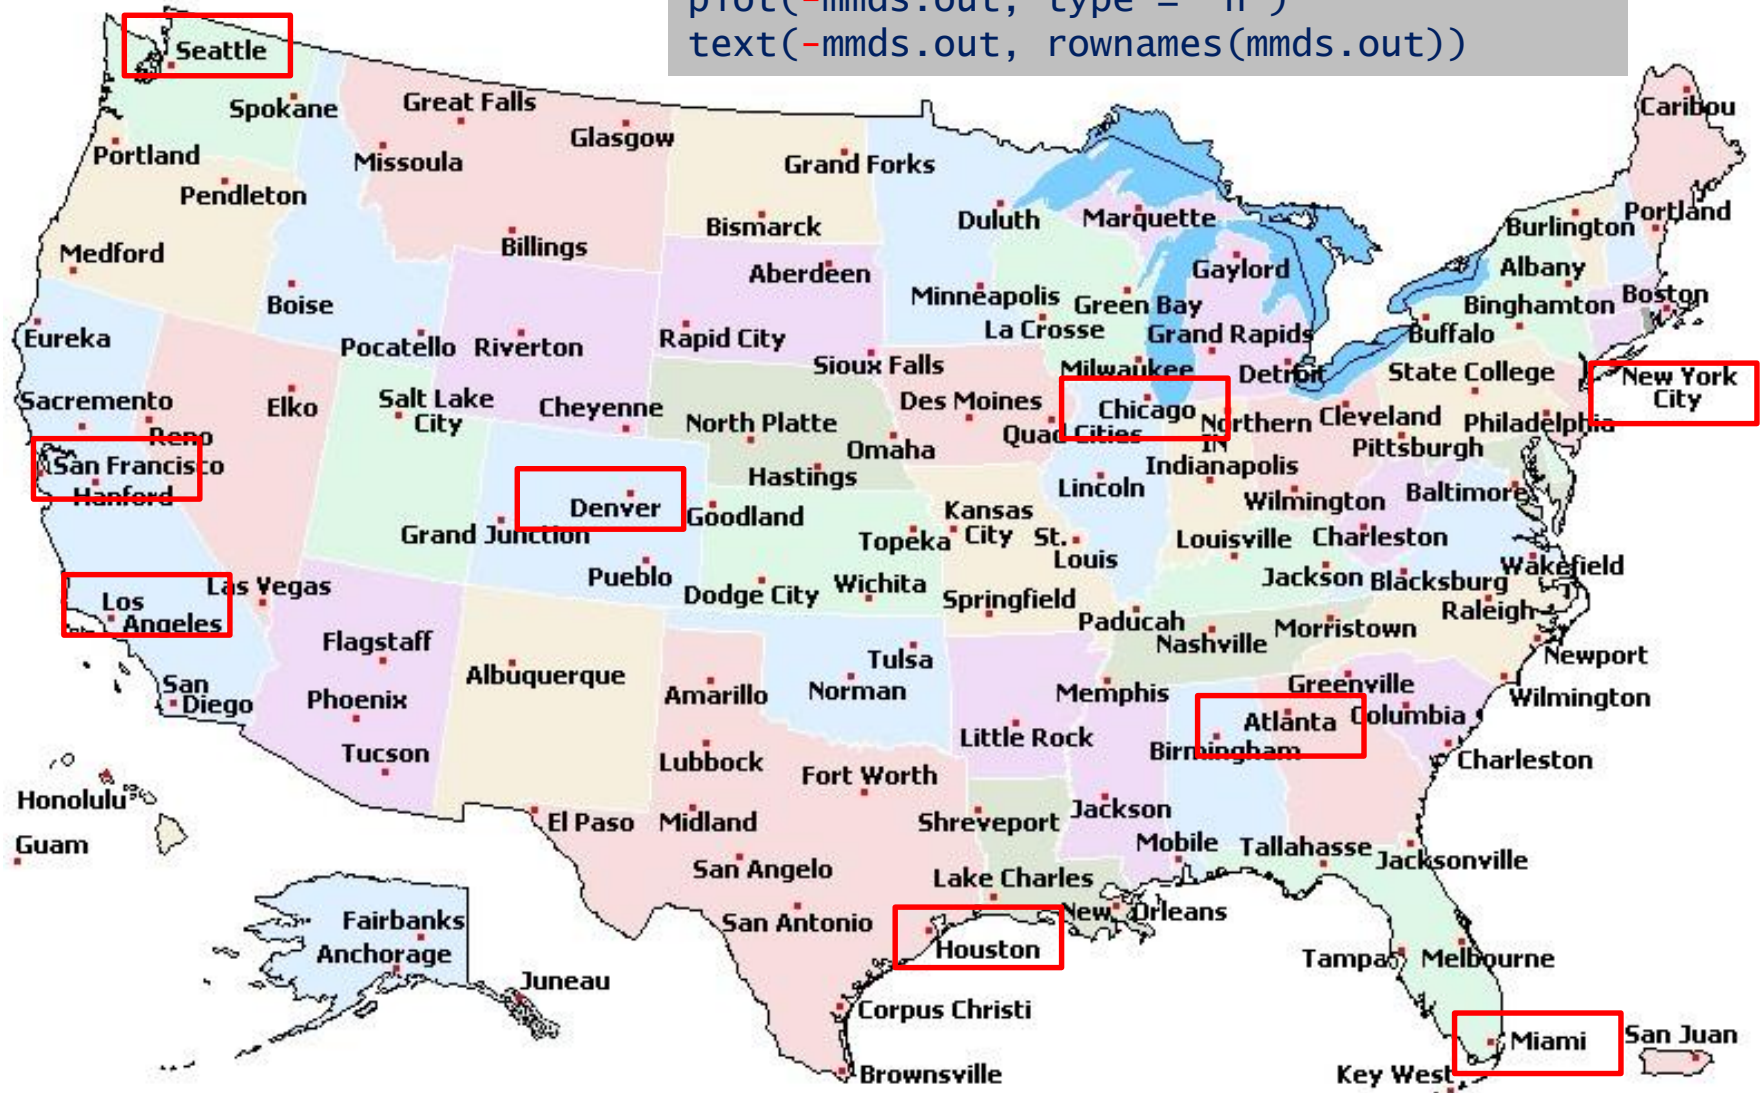
- 분석결과
 - ✓ 10개 미국 도시 간의 거리를 기반으로 2차원의 좌표값을 계산하여 mmds.out에 저장 (10 x 2 행렬)
 - ✓ 음과 양의 방향성은 의미가 없음 (PCA와 동일)
 - ✓ plot 함수를 이용하여 시각화
 - ✓ text 함수를 이용하여 plot 위에 도시명을 표시



소: PCA & MDS

2. MDS 방법

```
plot(-mmds.out, type = "n")  
text(-mmds.out, rownames(mmds.out))
```





2. MDS 방법 (USArrests 사용)

```
#prepare data
USArrests.scaled
USArrestsDist <- dist(USArrests.scaled)
USArrestsDist
#metricMDS
mmds2.out <- cmdscale(USArrestsDist)
mmds2.out
#plot the result
plot(mmds2.out)
plot(mmds2.out, type = "n")
text(mmds2.out, rownames(mmds2.out))
```



!축소: PCA & MDS




R

2. MDS 방법 (USArrests 사용)

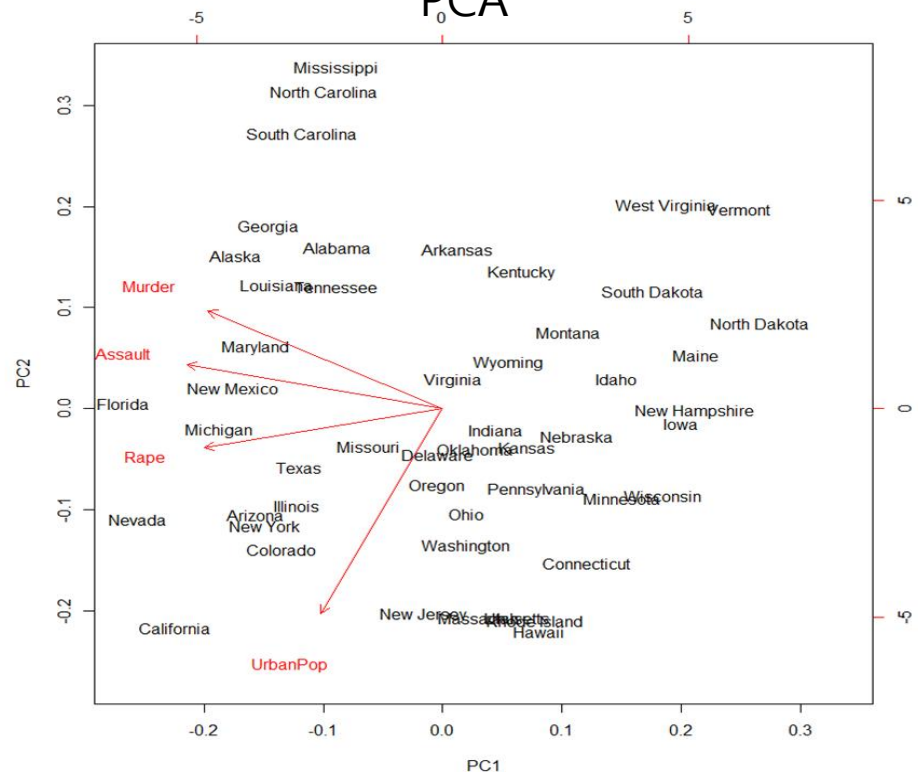
```
#MDS with Euclidean distances is identical to PCA
#Compare PCA output with MDS output (using Euclidean distance)
head(abs(prcomp(USArrests, scale. = T)$x))
head(abs(cmdscale(USArrestsDist, k=4)))
range(abs(prcomp(USArrests, scale. = T)$x)
      - abs(cmdscale(USArrestsDist, k=4)))

#Compare PCA output with MDS output (using Manhattan distance)
head(abs(cmdscale(dist(USArrests.scaled, method = "manhattan"), k=4)))
range(abs(prcomp(USArrests, scale. = T)$x)
      - abs(cmdscale(dist(USArrests.scaled, method = "manhattan"), k=4)))
```

MDS



PCA



2. Non-Metric MDS

- NMDS는 거리를 측정할 때 Euclidian distance가 아니라 **rank order**를 사용하는 것이 특징
- isoMDS() [MASS package]: Kruskal's non-metric multidimensional scaling.
- sammon() [MASS package]: Sammon's non-linear mapping

2. MDS 방법

2. Non-Metric MDS

- 19개 환경 법안에 대해 뉴저지 주 하원의원 15명이 다르게 투표한 횟수에 대한 데이터 (Romesburg, 1984)

```
# ① MASS 패키지와 데이터 설치 및 로드
install.packages("MASS")
library(MASS)
install.packages("HSAUR3")
data("voting", package = "HSAUR3")
view(voting)
# ② non-metric 다차원척도 분석
nm.ds.out <- isoMDS(voting)
nm.ds.out
nm.ds.out$points
# ③ 그림으로 확인
plot(nm.ds.out$points)
plot(nm.ds.out$points, type = "n")
text(nm.ds.out$points, rownames(nm.ds.out$points))
```

2. MDS 방법

	Hunt(R)	Sandman(R)	Howard(D)	Thompson(D)	Freylinghuysen(R)	Forsythe(R)
Hunt(R)	0	8	15	15	10	9
Sandman(R)	8	0	17	12	13	13
Howard(D)	15	17	0	9	16	12
Thompson(D)	15	12	9	0	14	12
Freylinghuysen(R)	10	13	16	14	0	8
Forsythe(R)	9	13	12	12	8	0
Widnall(R)	7	12	15	13	9	7
Roe(D)	15	16	5	10	13	12
Heltoski(D)	16	17	5	8	14	11
Rodino(D)	14	15	6	8	12	10
Minish(D)	15	16	5	8	12	9
Rinaldo(R)	16	17	4	6	12	10
Maraziti(R)	7	13	11	15	10	6
Daniels(D)	11	12	10	10	11	6
Patten(D)	13	16	7	7	11	10



2. MDS 방법

```
> nmds.out <- isoMDS(voting)
initial value 15.268246
iter 5 value 10.264075
final value 9.879047
converged
> nmds.out
$points
```

	[,1]	[,2]
Hunt(R)	-8.4354008	0.9063380
Sandman(R)	-7.4050250	7.8770232
Howard(D)	6.0930164	-1.4971986
Thompson(D)	3.5187022	5.2486888
Freylinghuysen(R)	-7.2457425	-4.1821704
Forsythe(R)	-3.2787096	-2.5689673
Widnall(R)	-9.7110008	-1.1187710
Roe(D)	6.3429759	1.0388694
Heltoski(D)	6.2983842	0.2706499
Rodino(D)	4.2829160	-0.9151604
Minish(D)	4.2642545	-0.3919690
Rinaldo(R)	5.0285425	0.2665701
Maraziti(R)	-4.4577693	-6.2177727
Daniels(D)	0.8129854	-0.9417672
Patten(D)	3.8918709	2.2256372


```
$stress
[1] 9.879047
```



2. MDS 방법

- 분석결과
 - ✓ MASS 패키지에 포함된 isoMDS 함수로 non-metric MDS 수행
 - ✓ nmds.out에 2차원 좌표값 뿐 아니라 stress 값(**퍼센트**)까지 저장
 - Stress (원래 차원에서의 거리와 축소된 차원에서의 거리 간 차이)를 최소화 하는 방법
 - Stress 기준(Clarke, 1993)
 - » > 0.20 is basically random
 - » < 0.20 is usable
 - » < **0.10 is good**
 - » < 0.05 is excellent
 - ✓ plot 함수의 입력값으로 nmds.out\$points를 사용
 - ✓ 도시 이름도 nmds.out\$points에서 받아오도록 함(text 함수)

2. MDS 방법



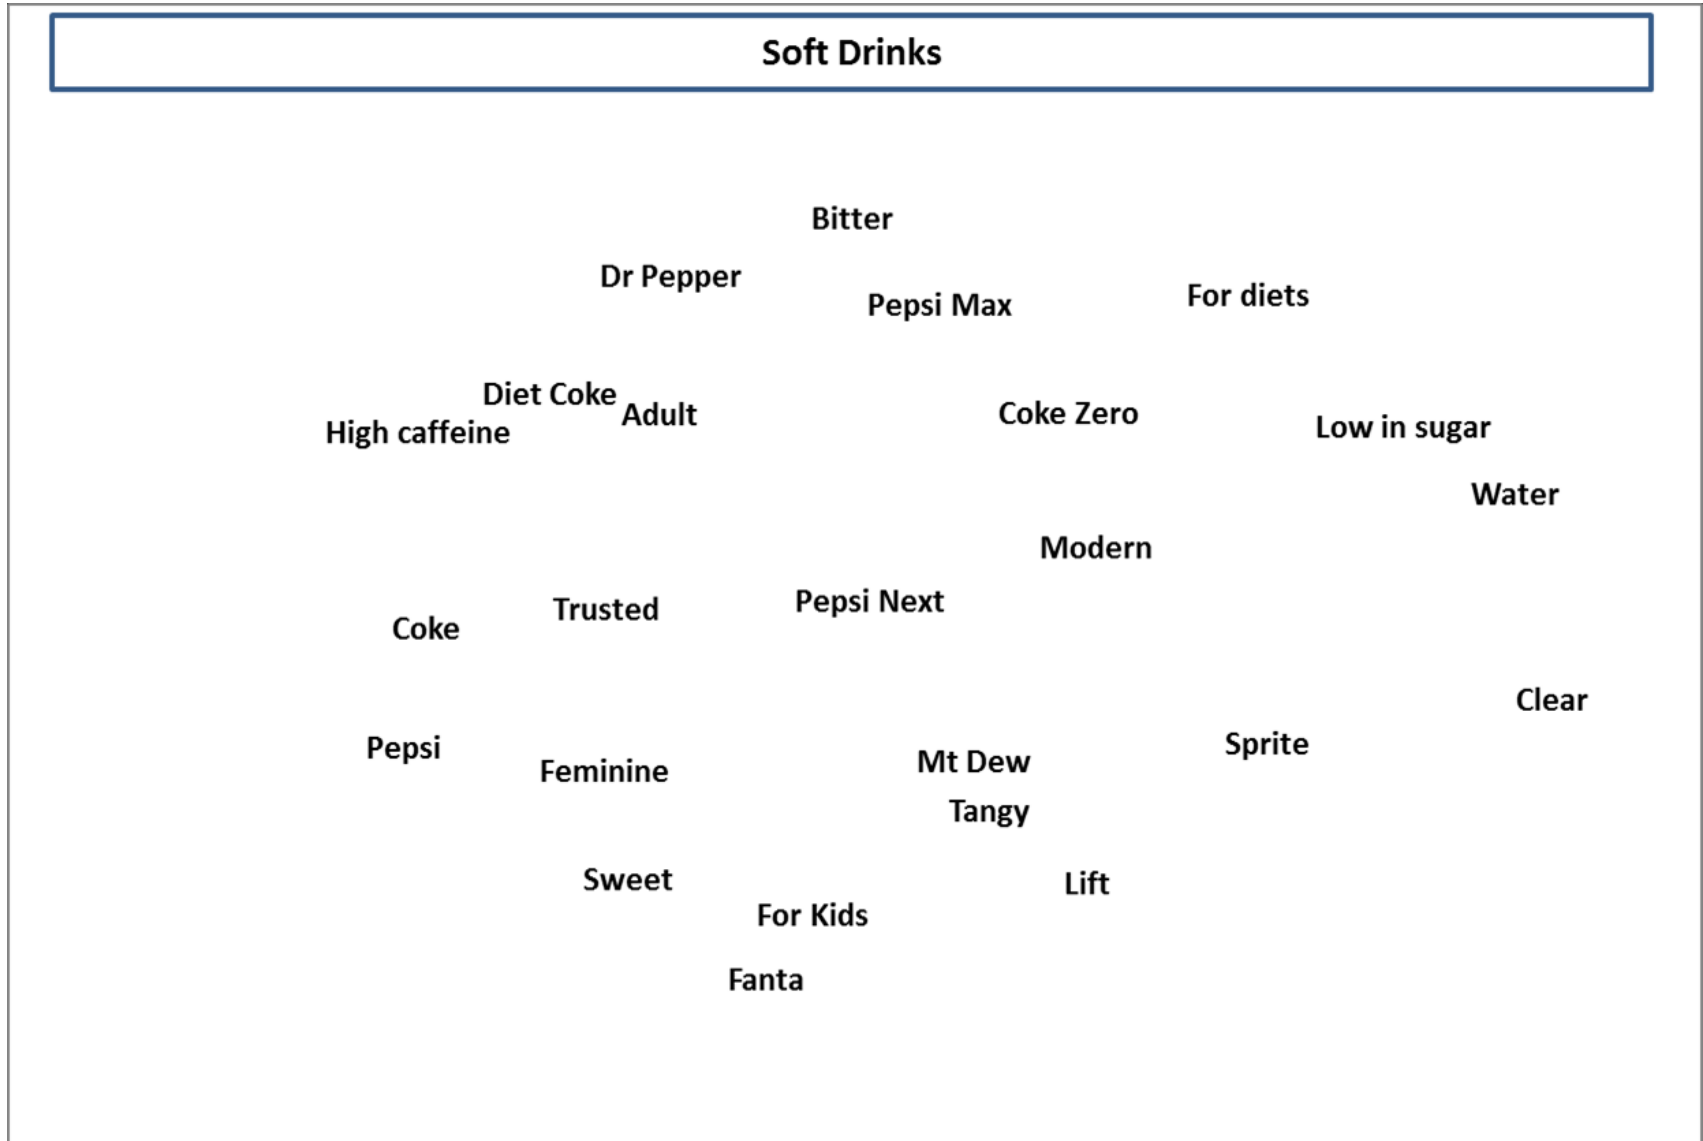
제품간 유사도 측정

10명의 소비자들이 여덟 개의 승용차 브랜드들에 대한 유사성 지각(28개 쌍 비교).

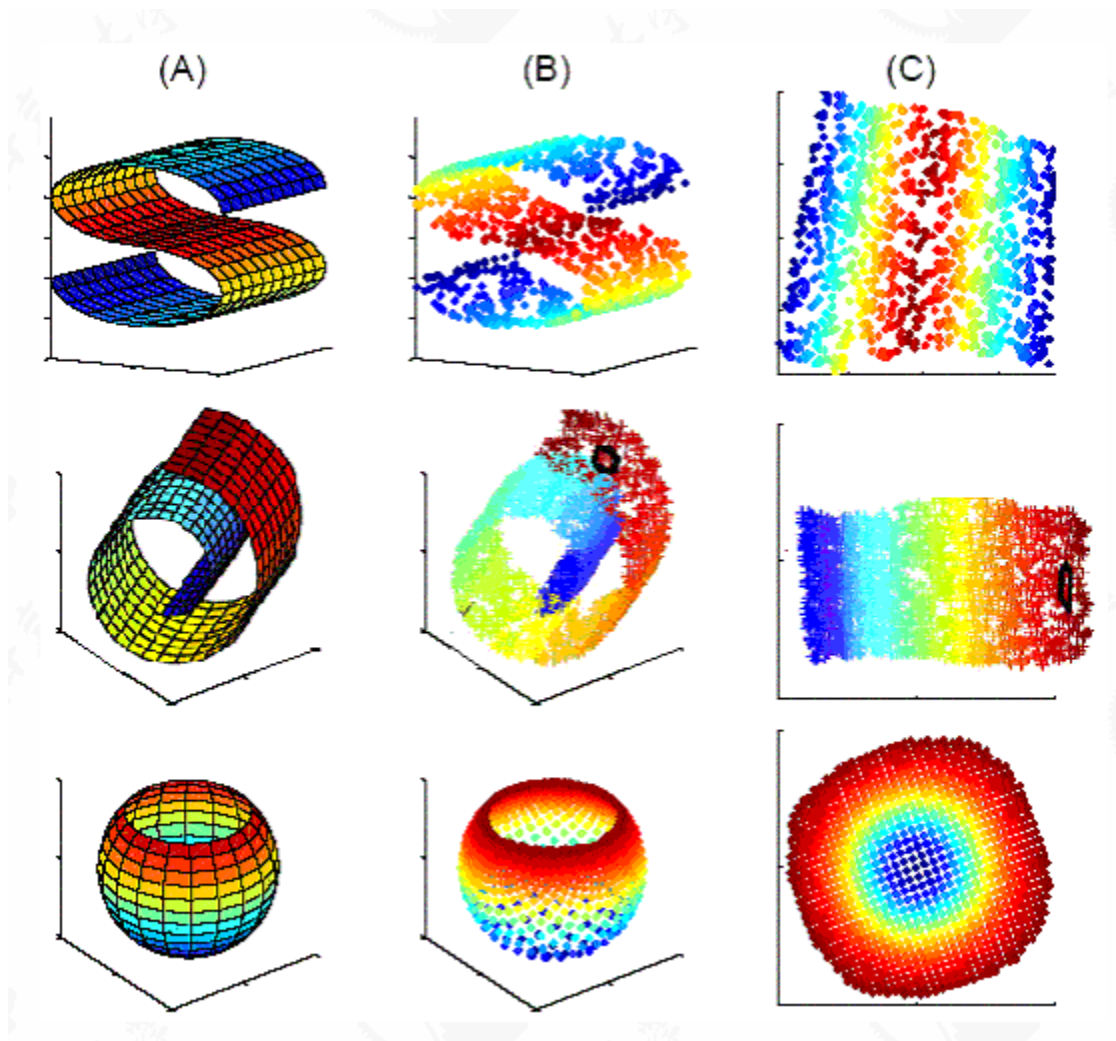
질문: 다음 각각의 두 브랜드가 어느 정도 유사하다고 느끼십니까?

1. 프라이드 - XG	1	2	3	4	5	6	7
	매우 유사하다			보통이다			전혀 다르다
2. 프라이드 - 쏘나타	1	2	3	4	5	6	7
	매우 유사하다			보통이다			전혀 다르다
3. 프라이드 - 베르나	1	2	3	4	5	6	7
	매우 유사하다			보통이다			전혀 다르다
..... < 생략 >							
27. 체어맨 - 칼로스	1	2	3	4	5	6	7
	매우 유사하다			보통이다			전혀 다르다
28. 매그너스 - 칼로스	1	2	3	4	5	6	7
	매우 유사하다			보통이다			전혀 다르다

다차원척도법을 활용한 제품 세분화



*비선형 차원축소



집앞 초밥집이 나한테 깨달음을 줬어

